



CENTRO UNIVERSITÁRIO DE BRASÍLIA - CEUB

Caio Barbosa de Lima - 22400449

Guilherme Augusto da Silva Henriques - 22409093

Gustavo Albuquerque de Oliveira - 22402765

Lucas Bretas Prata de Pinho Tavares - 22400039

Mateus Onival Araujo de Moraes - 22402037

Relatório de Conformidade – LGPD e Segurança de Dados

BRASÍLIA - DF

2026

1. Descrição do Cenário

- **Contexto do sistema ou base de dados analisada:** O sistema consiste em um pipeline ETL e um Dashboard Web interativo desenvolvido em Streamlit para analisar as interconexões entre o mercado de apostas online (BETs), o uso do PIX e o endividamento/saúde mental das famílias brasileiras.
- **Tipo de dados coletados:** Dados de fontes governamentais agregadas (BCB), microdados epidemiológicos (DataSUS - CID-10 F63.0) e de defesa do consumidor (Consumidor.gov.br). Trata-se de dados públicos e sensíveis (envolvendo transtornos de saúde mental e ideação suicida), mas estritamente anonimizados.
- **Finalidade declarada para uso dos dados:** Produzir insights estatísticos e visuais para subsidiar legisladores na regulação do setor, orientar profissionais de saúde e promover a conscientização da sociedade sobre os riscos da ludopatia.

2. Riscos Identificados

- **Possíveis violações da LGPD:** O principal risco estaria no tratamento inadequado dos microdados brutos que pudesse levar à quebra do anonimato dos pacientes em tratamento de saúde mental ou de indivíduos financeiramente vulneráveis.
- **Riscos de reidentificação ou exposição de dados:** Risco de engenharia reversa nos registros descritivos das reclamações do Consumidor.gov.br caso Informações Pessoalmente Identificáveis (PII) passassem pelos filtros.
- **Falhas de segurança ou ausência de controles:** Possíveis vulnerabilidades no frontend da aplicação contra ataques de *Cross-Site Scripting* (XSS) ou exploração maliciosa de links externos via *tabnabbing*.

3. Medidas de Segurança Aplicadas

- **Técnicas de anonimização ou pseudonimização utilizadas:** O pipeline trabalha exclusivamente com microdados médicos previamente anonimizados. Adicionalmente, para proteger dados demográficos e financeiros detalhados que não estavam totalmente disponíveis, o sistema utiliza algoritmos de imputação estatística (distribuições **normal** e **lognormal** no **numpy**), criando dados 100% sintéticos e simulados em memória.

- **Políticas de controle de acesso:** A versão atual foca na apresentação pública de agregados. O repositório e o código-fonte, porém, mantêm rígido controle de versionamento.
- **Procedimentos de retenção e descarte de dados:** O tratamento de grandes bases (como as extrações de arquivos `.zip`) e o processamento ETL ocorrem diretamente em memória no Pandas e através de `cache (@st.cache_data)` otimizado, sem a necessidade de reter arquivos brutos sensíveis a longo prazo de forma exposta.
- **Monitoramento e auditoria de acessos:** Todo o fluxo de modificação estrutural do projeto passa pela trilha de auditoria dos *commits* no controle de versão Git/GitHub da equipe.

4. Adequação à LGPD

- **Finalidade:** Os dados são tratados com propósitos legítimos e específicos para geração de relatórios de impacto socioeconômico e saúde pública, sem qualquer viés comercial.
- **Necessidade:** A coleta é restrita ao essencial. Na etapa de "Filtragem Semântica" do ETL, o algoritmo purga dados irrelevantes e isola estritamente registros contendo termos como 'BET' ou 'BLAZE', descartando o resto.
- **Transparência:** A metodologia de extração, transformação e visualização está totalmente documentada e aberta para conferência pública e acadêmica
- **Segurança:** Implementação nativa de controles contra injeções pelo framework web e sanitização de URLs via atributos `rel="noopener noreferrer"` no momento do direcionamento
- **Direitos do titular:** Como não há banco de dados registrando informações diretas de CPF/Nomes e o projeto atua apenas com agregados macro, dados publicamente anonimizados e dados sintéticos mockados, as requisições de portabilidade e exclusão de PII não incidem sobre a plataforma, garantindo conformidade natural.

5. Conclusão e Recomendações

- **Síntese das medidas aplicadas:** A solução PI-BETS prova que é viável lidar com problemáticas sensíveis (saúde mental) utilizando Ciência de Dados segura, baseada em anonimização, simulação estatística e purificação em memória.

- **Pontos fortes da conformidade:** Mitigação drástica de violações de privacidade pela ausência de persistência de dados nominais (PII), respeitando integralmente os pilares de Necessidade e Adequação.
- **Melhorias sugeridas para maior segurança:**
 1. Para uma futura etapa (destinada ao monitoramento clínico por assistentes sociais e psiquiatras do PRO-AMJO), recomenda-se a implementação rigorosa de Controle de Acesso Baseado em Papéis (RBAC), aplicando criptografia no armazenamento e registro de *logs* de quem visualiza os prontuários.
 2. Aplicar cabeçalhos formais de Política de Segurança de Conteúdo (CSP) no backend para bloquear preventivamente quaisquer scripts externos maliciosos na página.